

과제 기술서: 확신성 추론

1. 과제 개요

자연어 추론(Natural Language Inference)은 두 문장의 관계를 함의/중립/모순 중 하나로 분류한다. 국립국어원에서는 슈퍼글루(SuperGLUE)의 커미트먼트뱅크(CommitmentBank)를 참조하여, 2020년과 2021년 ‘말뭉치 함의 분석 및 연구’ 사업을 통해 확신성 추론 말뭉치를 구축하였다. 이 말뭉치는 일반적인 자연어 추론 말뭉치와는 달리, 화자의 인식에 비추어 맥락과 제시 문장 간 함의 관계를 정도성으로 판단한다. 데이터 세트는 제시 문장(prompt)에 대하여 주어진 맥락(context)을 고려하였을 때 화자가 확신하는 정도를 1~7 사이의 실수(float)로 표현하는 방식으로 구성되어 있다. 숫자가 1에 가까운 낮은 숫자일수록 제시된 문장에 대해 화자가 확신하는 정도가 낮고, 숫자가 7에 가까운 높은 숫자일수록 화자가 확신하는 정도가 높다고 해석한다.

항목	내용
맥락(Context)	17세기 영국 혁명에 대한 논쟁에서 순수 경제 결정론자들에 반대하여 청교도 정신 (Puritanism)의 중요성에 대해 변함없이 주장했던 크리스토퍼 힐 (Christopher Hill)이 마르크스주의자라는 사실을 깨닫는 사람은 많지 않다. 힐은 청교도 정신을 사람들이 믿었던 중요한 것으로 보았지, 계급 구조나 경제 운동 위에 있는 시시한 것에 불과하다고 보지 않았다.
제시 문장(Prompt)	청교도 정신은 계급 구조나 경제 운동 위에 있는 시시한 것에 불과하다.
확신성 점수	1.625

표 1 확신성 추론 과제 데이터 세트의 예시

2. 과제 정의

확신성 추론 과제는 국립국어원에서 2020년과 2021년 ‘말뭉치 함의 분석 및 연구’ 사업을 통해 구축한 “추론-확신성 분석 말뭉치”를 활용한다. 해당 데이터 세트의 확신성 점수는 1~7 사이의 실수로 표현되어 있다. 확신성 추론 과제는 입력(Context, Prompt)에 대해 실숫값을 예측하는 방식으로 정의되어 있다. 공개된 ‘추론-확신성 분석 말뭉치’에는 여러 명의 주석자(8~20명)가 화자의 확신성을 평가한 결과가 모두 주석되어 있는데, 이 과제에서는 평균을 정답 점수로 간주한다. 참가자들은 평가 데이터 세트의 입력 (context, prompt)을 기반으로 1~7 사이의 확신성 점수를 예측한다. 평가 지표는 MSE(Mean Squared Error) 점수이다.

분류	내용	예시	비고
입력	Context	"준플레이오프가 5전3선승제로 바뀐 2008년 이후 하위팀이 상위팀을 두 번이나 꺾고 한국시리즈에 오른 것은 두산이 처음이다. 두산은 마지막 우승이었던 지난 2001년에도 준플레이오프부터 시리즈를 시작해 한국시리즈 우승을 차지한 바 있다. 두산은 마지막 우승 당시 한국시리즈 상대가 삼성이었	문자열

		음을 기억하고 있을 것이다."	
	Prompt	"두산의 마지막 우승 당시의 한국시리즈 상대는 삼성이었다."	문자열
출력	확신성 점수	6.375	실수 (Float)
평가	MSE		

표 2 확신성 추론 과제의 입력과 출력의 예

MSE는 각 데이터에 대해 정답 점수와 예측 점수 간의 차이를 제공하여 평균한 값이다. 이러한 평가 방법은 오차에 대해 제공하는 방법이기 때문에 점수 간의 편차가 크게 발생할 수 있으나 양의 오차와 음의 오차를 상관없이 독립적으로 측정할 수 있기 때문에 널리 쓰이는 평가 방법이다.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

그림 1 MSE 점수 측정 방법

확신성 추론 과제는 1~7 사이의 실수를 예측하는 과제이므로, 정답과의 오차가 2점 발생하게 되면 MSE 평가에서는 4점으로 측정된다. 우수한 MSE 평가의 객관적인 기준을 제시할 수는 없으나 이 과제의 난도를 고려할 때 오차가 1~2점 이내일 경우에는 유의미한 결과라고 평가될 수 있을 것이며, 1점 이내일 경우에는 우수한 결과라고 평가해도 무리가 없을 것이다. 따라서 MSE 점수가 4점 이하일 경우 보통의 결과, 2점 이내일 경우 우수한 결과로 간주할 수 있다.

순위표(리더보드)에서는 더 큰 값을 상위 등수로 표현하기 위해 MSE 점수에 -1을 곱한 후, 점수의 크기를 부각하기 위해 100을 곱한 값을 표시한다(즉 순위표 표시 점수 = -100 * MSE값).

3. 데이터 형식

데이터 세트는 제이슨-엘(JSON-L, jsonlines) 형식으로 제공되며, 각 입력(Context, Prompt) 문장들에 대한 확신성 점수가 실수(float)로 주석되어 있다.

표 3은 데이터 규모를 보여준다. 출력(output)값의 분포가 유사하도록 무작위로 분할되었다.

구분	훈련	검증	시험
문장 수	1,448	189	180

표 3 데이터 규모

표 4는 데이터 형식의 예시이다. 주어진 훈련 데이터와 시험 데이터는 동일한 제이슨-엘(JSON-L) 형식으로 제공되며, 시험 데이터의 경우에는 각 문장에 대한 출력(output) 항목이 없다. 참가 팀은 모델의 출력 결과를 추가하여 제출한다.



항목	내용
훈련용 데이터의 예	<pre> ... { "id": "nikluge-2022-nli-train-000001", "input": {"context": "준플레이오프가 5전3선승제로 바뀐 2008년 이후 하위팀이 상위팀을 두 번이나 꺾고 한국시리즈에 오른 것은 두산이 처음이다. 두산은 마지막 우승이었던 지난 2001년에도 준플레이오프부터 시리즈를 시작해 한국시리즈 우승을 차지한 바 있다. 두산은 마지막 우승 당시 한국시리즈 상대가 삼성이었음을 기억하고 있을 것이다.", "prompt": "두산의 마지막 우승 당시의 한국시리즈 상대는 삼성이었다."}, "output": "6.375"} ... </pre> - 아이디(id)와 입력 문장(input), 그리고 출력(1과 7 사이의 실수)으로 구성
평가용 데이터의 예 (제출 전)	<pre> ... { "id": "nikluge-2022-nli-train-000001", "input": {"context": "준플레이오프가 5전3선승제로 바뀐 2008년 이후 하위팀이 상위팀을 두 번이나 꺾고 한국시리즈에 오른 것은 두산이 처음이다. 두산은 마지막 우승이었던 지난 2001년에도 준플레이오프부터 시리즈를 시작해 한국시리즈 우승을 차지한 바 있다. 두산은 마지막 우승 당시 한국시리즈 상대가 삼성이었음을 기억하고 있을 것이다.", "prompt": "두산의 마지막 우승 당시의 한국시리즈 상대는 삼성이었다."}, } ... </pre> - 학습용 데이터와 동일한 형태 - “output” 키와 값을 제거한 데이터
제출용 데이터의 예	<pre> ... { "id": "nikluge-2022-nli-train-000001", "input": {"context": "준플레이오프가 5전3선승제로 바뀐 2008년 이후 하위팀이 상위팀을 두 번이나 꺾고 한국시리즈에 오른 것은 두산이 처음이다. 두산은 마지막 우승이었던 지난 2001년에도 준플레이오프부터 시리즈를 시작해 한국시리즈 우승을 차지한 바 있다. 두산은 마지막 우승 당시 한국시리즈 상대가 삼성이었음을 기억하고 있을 것이다.", "prompt": "두산의 마지막 우승 당시의 한국시리즈 상대는 삼성이었다."}, "output": "6.375"} ... </pre> - 평가용 데이터에 “output”과 확신성 점수를 추가하여 제출

표 4 데이터 형식의 예

4. 기준 모델

이 과제의 기준 모델(baseline model)은 깃허브(github)를 통해 공개되어 있다.¹⁾

(https://github.com/teddysum/korean_NLI_baseline)




그림 2 기준 모델 개념도

5. 참가 규정 및 제출 방법

(1) 팀 구성

- 국립국어원 ‘언어정보나눔터(모두의 말뭉치, 인공지능(AI)말평)’ 회원은 누구나 참가할 수 있다.

(2) 답안 제출

- 참가 팀은 해당 과제를 해결한 결과를 제공하는 양식(샘플) 파일과 동일한 형식으로 작성하여 제출한다.
- 한 참가 팀이 복수의 결과물을 제출할 경우 제출한 모델 및 결과 중 가장 높은 성적을 기준으로 순위표(리더보드)에 게시한다.

(3) 모델 사용 및 제출

- 라이선스에 문제가 없는 모델 사용 가능(라이선스의 검토 책임은 참가 팀에게 있음)
- 외부 API를 추론에 직접적으로 이용 불가(예: 챗GPT 결과 제출)
- 외부 데이터 추가 사용 가능
 - 외부에 공개된 모든 데이터를 학습 데이터로 사용 가능
 - 상시 과제로 제공된 데이터는 초거대 언어모델(LLM)을 이용하여 증강 후 학습 데이터로 사용 가능

(4) 기타: 시험 데이터의 정답은 공개 계획 없음

6. 문의: 과제의 ‘문의’ 게시판 이용

1) 이 모델은 XLM-RoBERTa 모델을 사용하여 학습되었으며, 모델 구조는 xlm-roberta-base 모델의 <s> 토큰 출력(output)에 FFRegression을 붙인 형태의 모델이다.